Modelo Multinível Não Linear para Predição de Vendas Semanais

Resumo

Este TCC tem como objetivo principal analisar os fatores que influenciam nas vendas da empresa Walmart utilizando técnicas de Machine Learning com um enfoque estatístico, com destaque para a eficiência da Modelagem Multinível [HLM3] “3 Level Hierarchical Linear Model” cujos conceitos foram usados para desenvolver um modelo hierárquico não linear com 3 níveis. Foram desenvolvidos modelos multiníveis usando diferentes distribuições (lineares e não lineares) e comparados passo a passo com os respectivos modelos sem paradigma multinível chamados “Generalized Linear Models” [GLM], ou seja, sem efeitos aleatórios. A eficácia da modelagem multinível foi avaliada por meio do desenvolvimento dos seus respectivos modelos nulos a fim de diagnosticar se o modelo é mais eficaz quando os dados são distribuídos em camadas hierárquicas. Foram estimados modelos nulos de Regressão Linear, Regressão Não Linear usando a transformação "Yeo-Johnson", Modelo Multinível HLM3 Linear e modelos completos de Regressão Linear e Regressão Não Linear para efeitos de comparação. Medidas estatísticas como Logaritmo de Máxima Verossimilhança [LogLik], “Akaike's Information Criterion” [AIC] e “Bayesian Information Criterion” [BIC] foram utilizadas para avaliar o desempenho de cada modelo.
A análise dos fatores que influenciam nas vendas da empresa Walmart utilizando técnicas de Machine Learning pode fornecer insights valiosos para aprimoramento das estratégias de vendas e tomada de decisão. A eficiência da modelagem multinível parece ser uma abordagem promissora para lidar com dados distribuídos em camadas hierárquicas. Os resultados obtidos neste estudo contribuem para a compreensão dos aspectos estatísticos relacionados ao tema e fornecem uma base sólida para pesquisas futuras na área.

Palavras-chave: Box-Cox; Modelo Multinível; Modelo Hierárquico; Machine Learning.

Considerações Iniciais

O Modelo Multinível de Regressão para Dados em Painel é derivado dos modelos de regressão para dados em painel e segundo Fávero e Belfiore (2017) é muito útil quando se deseja estudar o comportamento de determinado fenômeno, representado pela variável dependente, na presença de estruturas de dados agrupados, com medidas repetidas ou longitudinais.

Também de acordo com Fávero e Belfiore (2017), o Modelo Multinível de Regressão para Dados em Painel tem adquirido importância considerável em diversas áreas de conhecimento e a publicação de trabalhos tem se tornado cada vez maiores, muito em função da determinação de constructos de pesquisa que consideram a existência de estruturas aninhadas de dados, em que determinadas variáveis apresentam variação entre unidades distintas que representam grupos, porém não entre observações pertencentes a um mesmo grupo.

A escolha do Modelo Multinível Hierárquico se deve à sua eficiência em lidar com dados hierárquicos e sua capacidade de capturar a variação fornecida por diferentes níveis de agrupamento dos dados, pois tal modelo captura os efeitos aleatórios ao invés de capturar somente os efeitos fixos. Quando é constatada a existência de níveis, heterocedasticidade, a não normalidade aos resíduos mesmo após transformações que corrigem este problema e o uso de outros modelos que seriam mais apropriados mas na verdade não são, este modelo é uma grande opção a se considerar. Como o modelo é não linear e existem 3 níveis sendo um deles o tempo em semanas, foi usado o Modelo Hierárquico Linear de 3 Níveis com Medidas Repetidas [HLM3] após transformação para estabilizar a variância e tornar os dados mais próximos de uma distribuição normal. Conforme discutido por Fávero, Santos e Serra (2018a), um pesquisador também pode propor modelos hierárquicos não lineares,

O algoritmo proposto tem a finalidade de realizar análises supervisionadas visando entender a relação entre as variáveis explicativas e a variável dependente, entender a relação entre os níveis do modelo, entender como cada nível influencia na predição e identificar os coeficientes da equação do modelo final, auxiliando assim no processo de tomada de decisão.

Embora a modelagem multinível seja uma abordagem eficaz, este método apresenta algumas limitações. Dentre elas, destaca-se a necessidade de uma quantidade adequada de dados para garantir resultados robustos, bem como exige um maior poder de processamento computacional.

O fluxo do desenvolvimento deste TCC foi baseado nas etapas de desenvolvimento de um modelo preditivo no campo da Ciência de Dados que consiste em:

i) Obtenção dos dados
ii) Limpeza dos dados
iii) Análise exploratória de dados
iv) Seleção de recursos
v) Criação do modelo
vi) Treinamento do modelo
vii) Avaliação do modelo
viii) Ajuste do modelo

Utilizar vendas semanais como variável dependente do modelo é eficiente para eventos sazonais como por exemplo feriados, Black Friday, etc. No caso de feriados é importante notar que a semana torna-se uma referência, pois as compras começam a aumentar significavelmente em torno de 1 semana antes, e após o feriado o comércio abre

uma temporada de grandes descontos. Nota-se que a gestão de estoque, o planejamento de promoções e alocação de recursos também se beneficiam com essa abordagem semanal.

Como este TCC levou em conta as compras em lojas físicas, a questão de se prever vendas semanais se torna mais precisa pois nem todas as lojas abrem no feriado e dependendo do local nenhuma abre as portas.

Implementação de Algoritmo(s) de Machine Learning

A planilha utilizada neste TCC foi gerada de uma lista de planilhas com dados sobre vendas semanais de produtos em diferentes lojas da empresa Walmart nos Estados Unidos da América. Foram encontrados alguns trabalhos usando este dataset e a variável dependente não era vendas semanais por departamento, pois a coluna de departamento foi retirada e as vendas se tornavam por loja, mostrando assim o desafio de implementar o modelo deste TCC. A implementação do Modelo Multinível HLM3 acontece o oposto: o campo Departamento do dataset é necessário.

O maior desafio nesta etapa de obtenção e limpeza de dados foi escolher uma ou mais colunas de remarcações de desconto chamadas de MarkDown 1, 2, 3, 4 e 5. São remarcações, descontos oferecidos pelas lojas. A Figura 1 apresenta um gráfico com todos os descontos. Haviam muitos valores NA's nas colunas MarkDown 2, 3 e 4, mas MarkDown 1 tinha uma quantidade pequena e MarkDown5 não havia nenhum valor NA. Por isso foram mantidos os campos MarkDown 1 e 5 que por acaso são os valores das remarcações do início e fim da semana, respectivamente. Além disto, os valores de marcações de descontos estavam disponíveis só a partir de novembro de 2011, por isto a escolha só do ano de 2012.

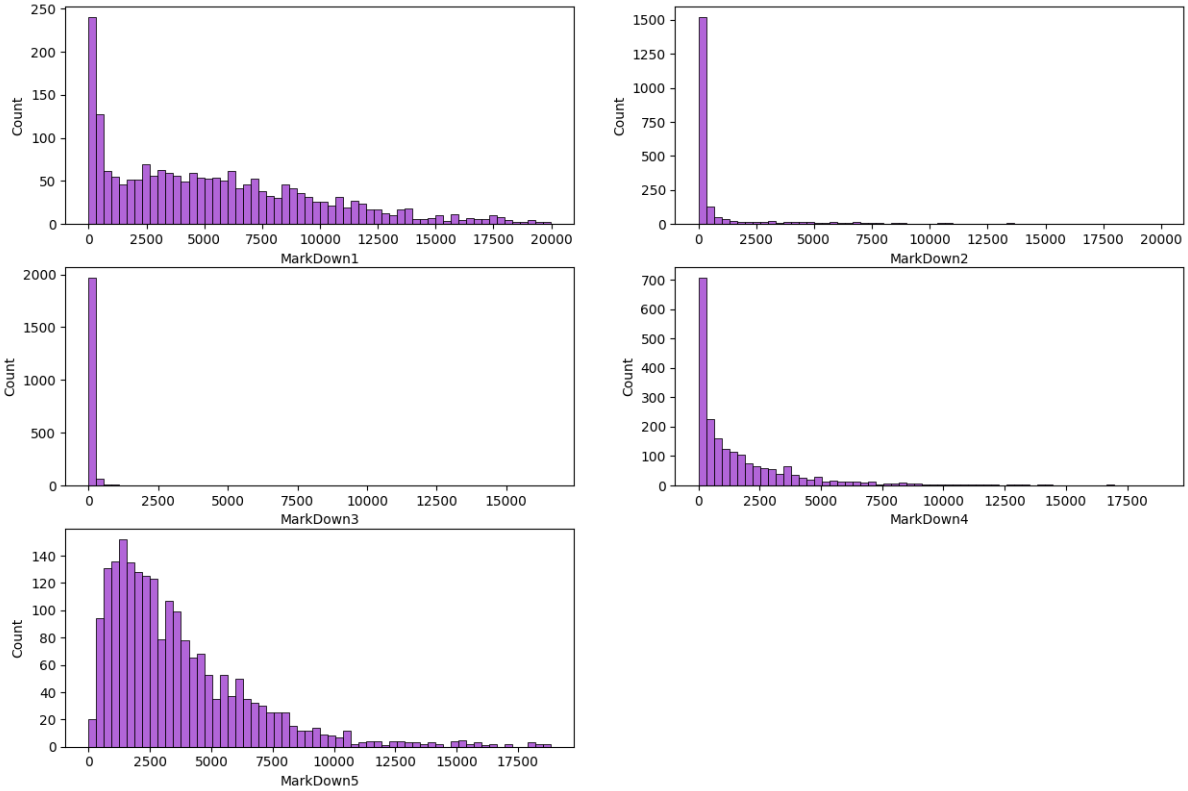

Figura 1. Gráficos de frequência dos 5 colunas de desconto
Fonte: Dados originais da pesquisa

As descrições das colunas contidas na planilha seguem abaixo:

i) Store: Código da loja, categórica de 1 a 45

ii) Week: Número da semana, inteira de 1 a 42

iii) Temperature: Temperatura, decimal

iv) Fuel_Price: Preço da gasolina, decimal

v) MarkDown1 Remarcação de desconto de abertura, decimal

vi) MarkDown5: Remarcação de desconto de fechamento, decimal

vii) CPI: Índice de Preços ao Consumidor, decimal

viii) Unemployment: Taxa de desemprego, decimal

ix) IsHoliday: “é feriado”, booleana que mostra se é feriado ou não

x) Dept: Código do departamento, categórica

xi) Weekly_Sales: Vendas semanais, inteira

xii) Type: Tipo de loja, categórica com valores A, B e C

xiii) Size: Tamanho da loja, inteira

A obtenção, limpeza e análise exploratória de dados foram realizadas através do uso das linguagens de programação Python e R usando o Jupyter Notebook e Rstudio como ambiente de desenvolvimento. A criação, treinamento, avaliação e ajuste do modelo foram realizados através do uso da linguagem R usando o Rstudio como ambiente de desenvolvimento. São todas ferramentas de código livre e aberto.

Os dados contidos na planilha foram importados para o ambiente de desenvolvimento. As propriedades dos valores das colunas após a limpeza e tratamento de dados são mostradas na Tabela 1.

Tabela 1. Lista das colunas com nome, número de dados não nulos e tipos

Column	Non-Null	Dtype
Store	151432	category
Week	151432	int64
Temperature	151432	float64
Fuel_Price	151432	float64
MarkDown1	151432	float64
MarkDown5	151432	float64
CPI	151432	float64
IsHoliday	151432	category
Dept	151432	category
Weekly_Sales	151432	int64
Type	151432	category
Size	151432	int64
Unemployment	151432	float64

Fonte: Dados originais da pesquisa

Os dados estatísticos de cada coluna numérica antes de aplicar a técnica Z-Score e eliminar os outliers foram inseridos nas tabelas 2 e 3.

Tabela 2. Estatísticas descritivas das colunas Temperature, Fuel_Price e MarkDown 1 e 5

Estatísticas	Temperature	Fuel_Price	MarkDown1	MarkDown5
Count	151432	151432	151432	151432
Mean	15.4445	3.6587	7210.48	4628.97
Min	13.6333	3.031	0	135.16
25%	8.4	3.476	2211.62	1878.44
50%	16.0444	3.666	5320.71	3359.45
75%	23.2611	3.864	9198.08	5563.80
Max	37.8167	4.468	88646.80	108519
STD	9.801998	0.289306	8286.287331	5962.883796

Fonte: Dados originais da pesquisa

Tabela 3. Estatísticas descritivas das colunas CPI, Unemployment, Weekly_sales e Size

Estatísticas	CPI	Unemployment	Weekly_Sales	Size
Count	151432	151432	151432	151432
Mean	0.174780	7.401	16174.29	136361.49
Min	0.129817	3.879	0	34875
25%	0.136491	6.334	1997.75	93638
50%	0.189062	7.244	7537.50	140167
75%	0.219905	8.256	204.16	202505
Max	0.227233	12.890	470000	219622
STD	0.040344	1.723361	23178.224555	61114.170844

Fonte: Dados originais da pesquisa

Em seguida foi realizado um procedimento para incluir as variáveis categóricas na modelagem. Todos os valores das variáveis categóricas foram transformados em colunas com valores 0 ou 1 indicando sua presença ou não naquela determinada coluna. Este procedimento foi usado nas colunas Type e IsHoliday. Nos modelo não multiníveis também foi aplicado este procedimento na coluna Store.

A técnica usada para colocar valores numéricos inteiros representando cada valor nas colunas com valores categóricos não é recomendada pois provoca muitos problemas e distorções no modelo final. Exemplo: substituir os valores “casa”, ”apartamento” e “fazenda” da coluna “domicílio” por 1, 2 e 3.

No gráfico de frequências da variável dependente na Figura 2 foi observado que a distribuição da variável assemelha-se à distribuição de Poisson Binomial Negativa, mas os valores eram decimais e existiam alguns valores negativos, o que não é permitido para aplicar o Modelo Binomial Negativo. Então os Valores negativos associados a devoluções não foram objeto de modelagem neste caso e foram tratados como ausência líquida de vendas e decimais em inteiros.

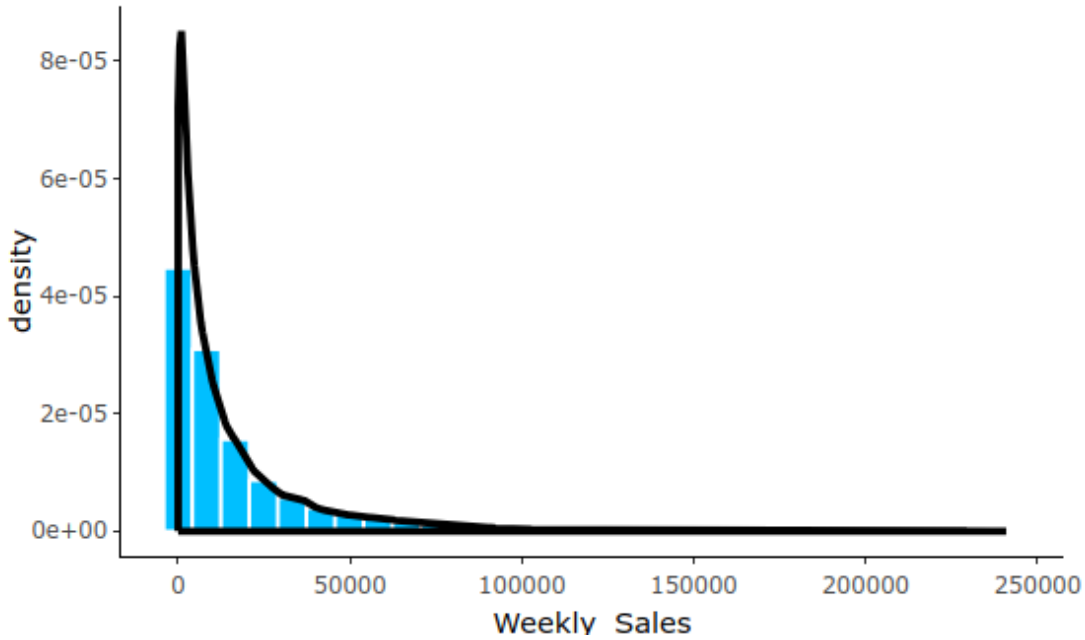

Figura 2. Distribuição da variável dependente Weekly_Sales
Fonte: Dados originais da pesquisa

Uma das condições para realizar a modelagem multinível com sucesso é que nenhum índice do nível inferior pode pertencer a mais de 2 grupos no nível superior. Exemplo: Nenhum bairro pode estar em 2 cidades diferentes. No caso deste TCC o segundo nível é departamento e cada departamento está numerado de 1 até n números de departamentos da loja que é o nível 3. Então foi preciso mudar o índice dos departamentos em cada loja. Exemplo: Loja 1 tem 90 departamentos e os índices estão entre 1 e 90. A próxima loja tem 80 departamentos e seus valores estavam entre 1 e 80. De acordo com a regra da modelagem multinível citada acima, os índices dos departamentos da loja 2 foram ajustados para o intervalo de 91 a 170 e assim sucessivamente.

Posteriormente, os dados numéricos foram padronizados para garantir que estivessem na mesma escala de medidas.. A padronização dos dados foi realizada com o procedimento chamado Z-Score. O tratamento dos outliers foi realizado usando a técnica chamada método Inter-Quartil pois alguns dados da coluna “Weekly_Sales” estavam demasiadamente altos como mostrado na Figura 3.

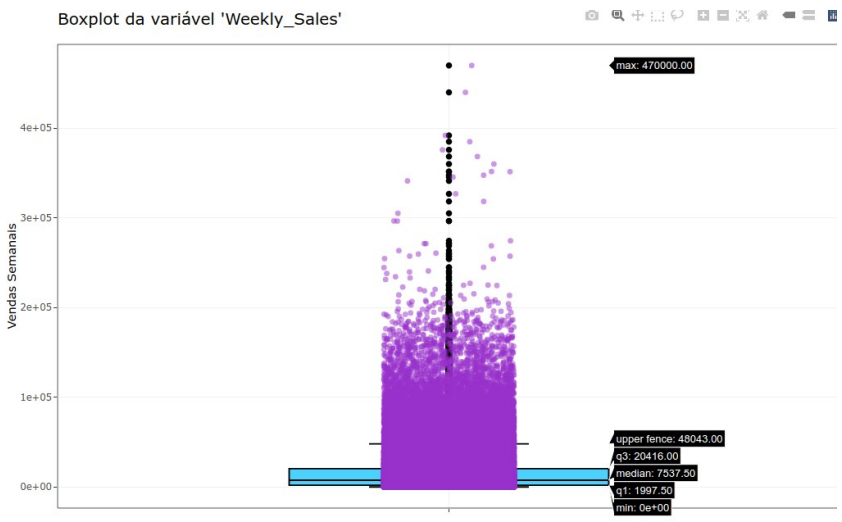

Figura 3. Distribuição dos outliers da variável dependente Weekly_Sales
Fonte: Dados originais da pesquisa

Foi preciso verificar se existe multicolinearidade pois poderia distorcer o modelo. Detecta-se a multicolinearidade através do cálculo de dois valores: “Variance Inflation Factor” [VIP] e Tolerance. VIP é o inverso do valor de Tolerance e tais valores diagnosticam a multicolinearidade. Se o valor da constante Tolerance é próximo de zero significa uma alta multicolinearidade e se for próximo de 1 significa multicolinearidade baixa. Se o valor de VIP tender a infinito significa uma multicolinearidade alta, mas se tender a 1 significa uma multicolinearidade baixa. No caso deste TCC não foram detectados casos de multicolinearidade como mostrado na tabela 4.

Tabela 4. Valores de VIP e Tolerance

Variáveis explicativas	VIF	Tolerance
const	6.097479	0.164002
Week	1.823292	0.548459
Temperature	1.745910	0.572767
Fuel_Price	1.452875	0.688290
MarkDown1	1.188364	0.841493
MarkDown5	1.136908	0.879578
CPI	1.344275	0.743895
Unemployment	1.238357	0.807522
Size	1.247109	0.801854

Fonte: Dados originais da pesquisa

Como o objetivo deste estudo é inferencial e comparativo entre estruturas de modelagem, e não otimização preditiva fora da amostra, optou-se por estimar os modelos utilizando a base completa de dados. A avaliação foi conduzida por meio de critérios baseados em verossimilhança (LogLik, AIC e BIC), em linha com o paradigma estatístico clássico. Reconhece-se que, no contexto preditivo de Machine Learning, a separação treino-teste é amplamente recomendada.

Os modelos GLM são chamados de “modelos de equação única”. A modelagem multinível é chamada de “modelo de múltiplas equações”, pois além dos termos típicos da equação final dos modelos supervisionados é possível capturar também os chamados “efeitos aleatórios” que são interações entre os níveis e dentro de cada nível. No caso de Modelo Hierárquico de 3 Níveis com Medidas Repetidas HLM3 existem 7 tipos de efeitos aleatórios. O efeito aleatório do nível 1 “Tempo” é chamado de Erro Idiossincrático[ε], efeito de intercepto[$v0jk$] de nível 2, efeito de inclinação[$v1jk$] de nível 2, efeito de intercepto[$\tau 00k$] de nível 3 e efeito de inclinação[$\tau 10k$] de nível 3. Os efeitos do nível 2 neste TCC significam “Existem diferenças de vendas semanais entre departamentos da mesma loja ao longo do tempo no que se refere ao intercepto e inclinação(ou taxas de crescimento)?” e os efeitos do nível 3 neste TCC significam “Existem diferenças de vendas semanais entre departamentos de lojas diferentes ao longo do tempo no que se refere ao intercepto e inclinação?”. Os índices t, j e k são respectivamente os índices do tempo, do departamento e da loja.

A figura 4 mostra a estrutura do modelo multinível HLM3.

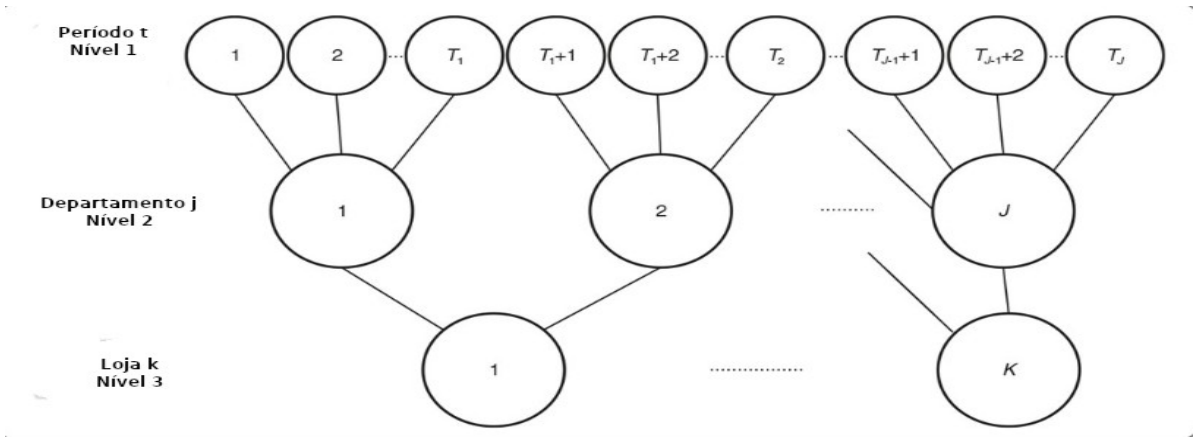

Figura 4. Modelo Hierárquico de 3 níveis cujo primeiro nível é o tempo
Fonte: Dados originais da pesquisa

Em modelos estatísticos, quando modelos GLM não conseguem se ajustar bem aos dados, o modelo estiver em níveis hierárquicos bem definidos e se constatar a existência de heterocedasticidade nos dados então o modelo multinível se torna uma ótima opção. Através de testes e gráficos é possível verificar se há heterocedasticidade. A

heterocedasticidade indica que a dispersão dos erros não é uniforme e aumenta cada vez mais conforme as variáveis envolvidas aumentam.

Ao constatar que o modelo multinível é a melhor opção, deve-se montar e executar o seu respectivo modelo nulo. No modelo nulo de um modelo de “Machine Learning” a variável dependente não tem variáveis explicativas, só o intercepto. Seu uso é frequente no mundo dos modelos de paradigma estatístico (GLM e GLLM por exemplo) para escolher o modelo mais eficiente observando métricas estatísticas como LogLik, AIC e BIC. O modelo nulo é usado também para observar se a inclusão ou exclusão de determinada variável explicativa foi benéfica para o modelo. O melhor modelo apresenta maior LogLik (menos negativo) e menores valores de AIC e BIC.

O modelo multinível é construído passo a passo a partir do modelo nulo, segundo a estratégia de “step-up” proposta por Raudenbush e Bryk (2002) pois não é possível aplicar o procedimento “Stepwise” em modelos multiníveis.

No caso da modelagem multinível, ao observar os valores aleatórios de cada nível do modelo nulo, é possível calcular a influência de cada camada sobre a variável dependente através de uma medida estatística chamada “Intraclass Correlation Coefficient” [ICC]. No caso deste TCC calculou-se a influência dos níveis departamento, loja e tempo sobre a variável dependente Weekly_Sales (vendas semanais).

As equações 1 e 2 foram usadas para desenvolver um modelo não linear hierárquico de 3 níveis usando a transformação de "Yeo-Johnson".

$$\frac{Y_i^{\lambda}-1}{\lambda}=\alpha+\beta_1 . X_{1i}+\beta_2 . X_{2i}+...+\beta_k . X_{ki}+u \tag{1}$$

$$Y_{tjk}=\beta_{0jk}+\beta_{1jk} . X_{jk}+...+\beta_{tjk} . X_{jk}+\varepsilon_{tjk} \tag{2}$$

onde Y : variável dependente; α: intercepto; β: Coeficientes; X: variáveis explicativas; k: índice de escola; u: termo de erro; λ: Lambda de "Yeo-Johnson"; t: índice de tempo; j: índice da departamento; ν, τ e ε: valores aleatórios dos níveis Departamento, Loja e Tempo respectivamente.

A transformação 'Yeo-Johnson' é semelhante a transformação de "Box-Cox", mas segundo Riani (2023) tem a vantagem de funcionar quando os dados apresentam números negativos e zeros.

,

Resultados e Discussão

Em seguida foi preciso obter a correlação entre as variáveis explicativas. As correlações foram observadas através do mapa de correlações na Figura 5.

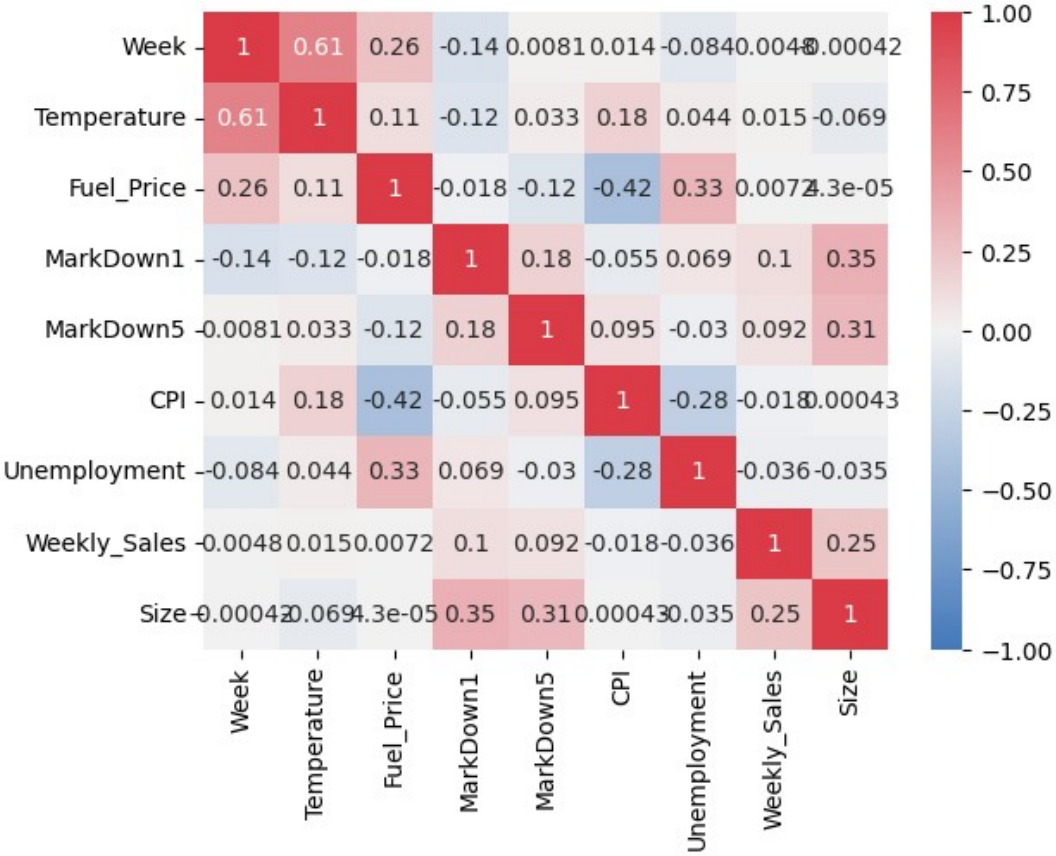

Figura 5. Correlações
Fonte: Resultados originais da pesquisa

De acordo com a Figura 5 foi detectado um caso correlação muito alta e nenhum caso de correlação perfeita (igual a um) que poderiam afetar o modelo. Notou-se também que várias variáveis explicativas têm pouca correlação com a variável dependente Weekly_Sales, então por consequência algumas destas variáveis não seriam estatisticamente significantes ao longo da modelagem e a predição da variável dependente não seria tão eficiente. Uma delas poderia ser a variável Week do nível 1. A Figura 6 mostra a média das vendas semanais das lojas e sua evolução no tempo e há uma variação muito pequena.

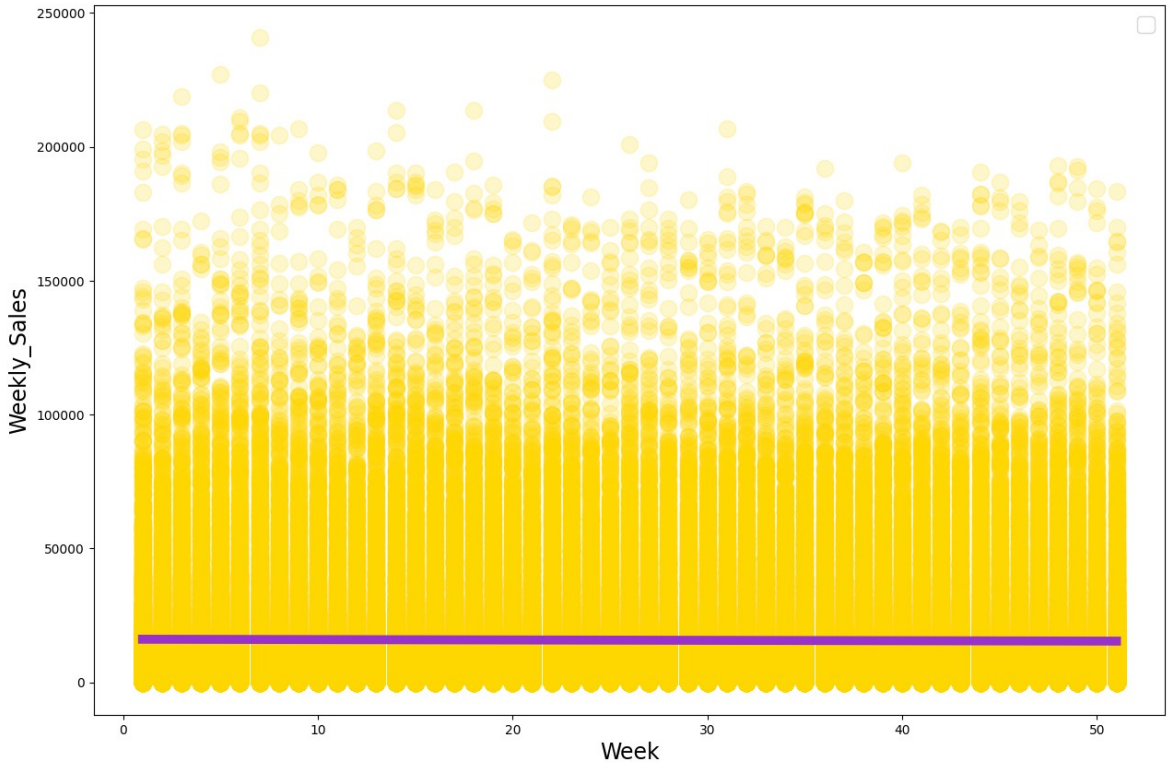

Figura 6. Média das vendas semanais no decorrer das semanas
Fonte: Resultados originais da pesquisa

Na Figura 7 que mostra as vendas das lojas ao longo das semanas, são apresentadas 10 lojas como exemplo. Há picos de vendas nos feriados americanos e há grupo de lojas bem definidas no que se refere às vendas semanais. Neste nível pode-se observar uma diferença nítida que há entre os interceptos (ponto de onde parte as vendas no eixo vertical), mas não grande, pois tanto nos interceptos como nas inclinações parecem formar pequenos padrões e quanto menos se vende tanto a diferença dos interceptos quanto das inclinações diminuem.

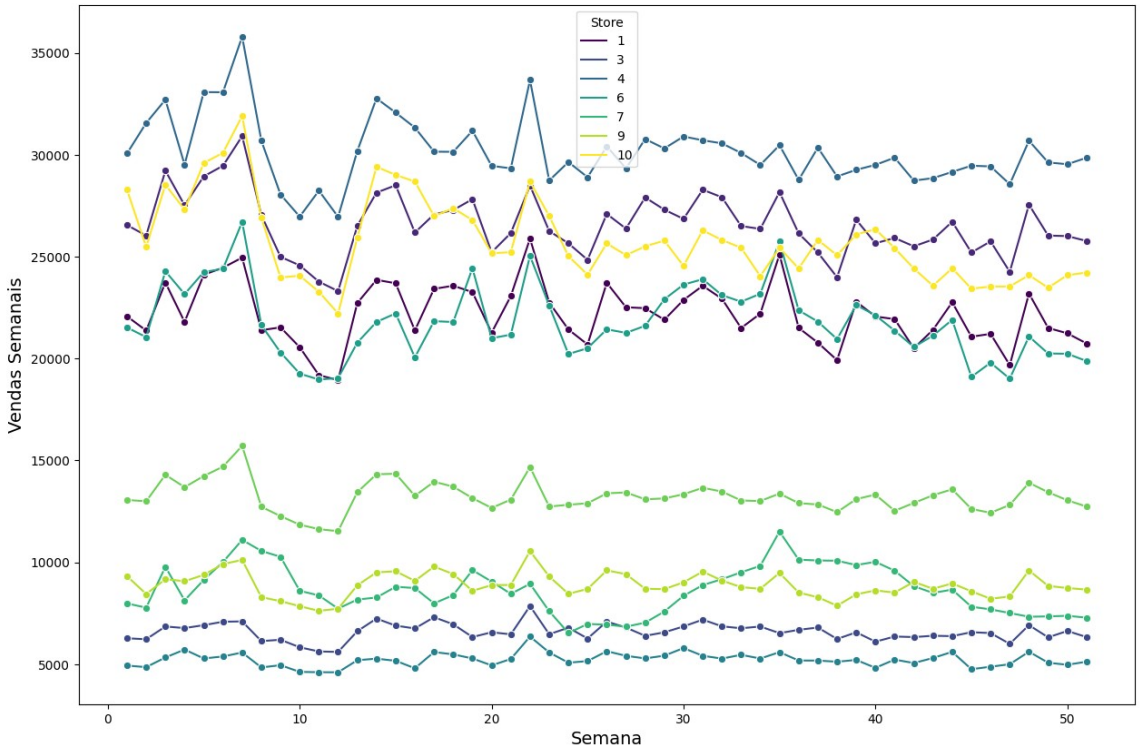

Figura 7. Vendas semanais das lojas no decorrer das semanas
Fonte: Resultados originais da pesquisa

Na Figura 8 que mostra as vendas dos departamentos dentro de uma loja ao longo das semanas são apresentados 10 departamentos da loja 1 e nota-se diferenças bem mais expressivas que no nível loja, tanto de intercepto como de inclinação.

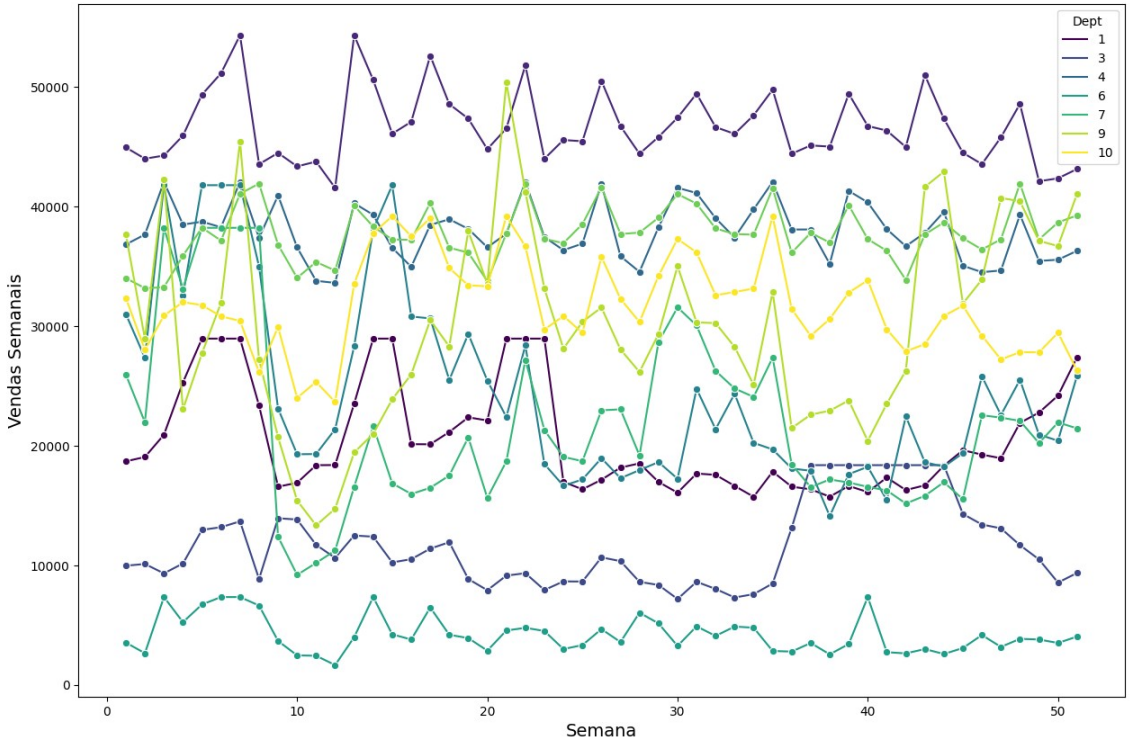

Figura 8. Vendas semanais dos departamentos da loja 1 no decorrer das semanas
Fonte: Resultados originais da pesquisa

Os gráficos anteriores e o gráfico Size x Weekly_Sales na Figura 9 mostraram que havia heterocedasticidade. Isso era esperado pois o tamanho da loja tem uma alta correlação com vendas semanais. Ao simular uma Regressão Linear os termos de erro aumentam mais ou menos na proporção do tamanho da loja. A variável Size e a variável Type são variáveis W do nível loja e segundo Hair e Fávero(2019), variáveis W são variáveis que não variam no seu respectivo nível.

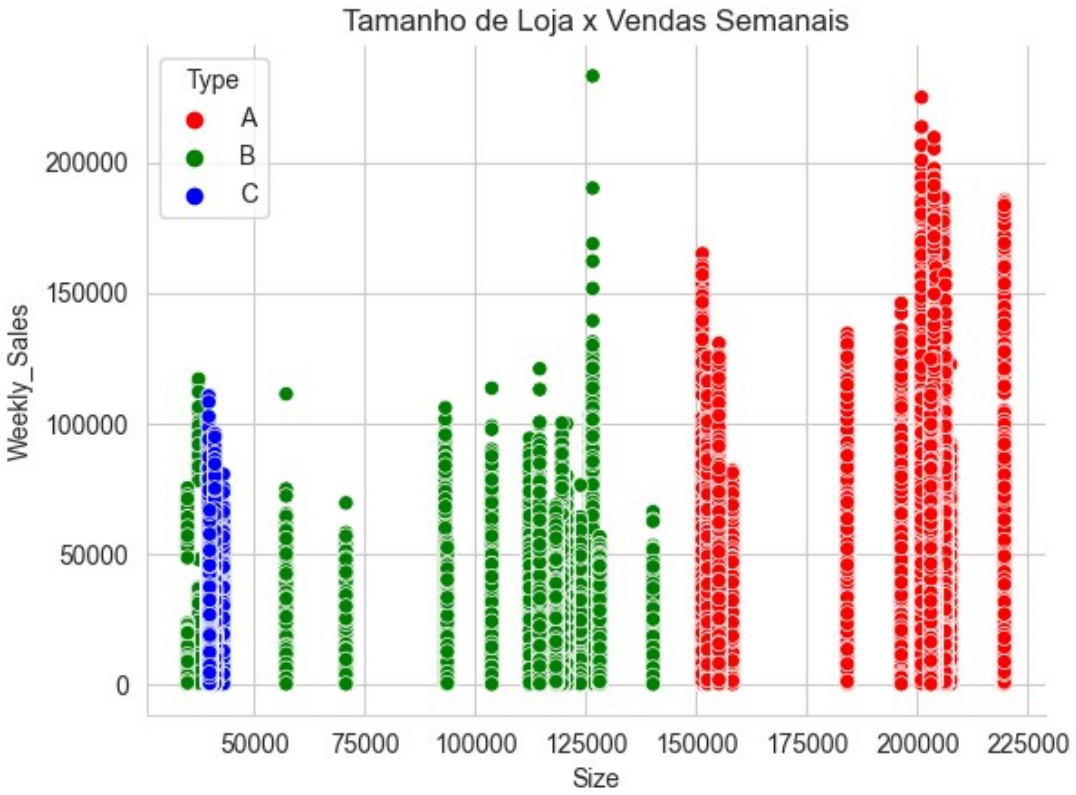

Figura 9. Gráfico tamanho da loja versus vendas semanais com a variável Type
Fonte: Resultados originais da pesquisa

Após a construção do Modelo Linear e logo em seguida o Modelo Não Linear com transformação de “Yeo-Johnson”, o teste de “Breusch-Pagan” deveria apresentar um p-value > 0,05 para não rejeitar a hipótese H0 de ausência de heterocedasticidade, mas foi encontrado um valor de p-value menor que 0.05, comprovando assim a heterocedasticidade. A não normalidade dos resíduos(também chamada de não aderência à normalidade) após o teste de “Shapiro-Francia” que também deveria apresentar um p-value > 0.05 foi muito menor, comprovando que os dados precisariam passar por algum tipo de transformação antes da modelagem em si. Como a heterocedasticidade e a não normalidade dos resíduos

continuaram após as transformações, constatou-se que o Modelo Multinível não Linear seria mais adequado, pois o lambda de "Yeo-Johnson" foi igual a `0.2129547` e não um, ou seja, modelo não linear. A variável dependente tem um formato que remete a uma distribuição Binomial Negativa.

Então o primeiro passo foi desenvolver modelos nulos de Regressão Linear, Não Linear com transformação de "Yeo-Johnson", Binomial Negativo e Binomial Negativo Multinível para comparar suas medidas estatísticas e qual se adequaria bem aos dados e à distribuição da variável dependente.

Para tornar o HLM3 não linear usa-se a coluna Weekly_Sales que foi transformada pelo lambda de “Yeo-Johnson” como variável dependente.

Escolha do tipo de modelo

Ao se estimar os modelos nulos e comparar seus respectivos valores de LogLik observou-se que o Modelo Multinível Binomial Negativo que seria a melhor opção de modelo de acordo com o gráfico da frequência da variável dependente não se ajustou bem aos dados pois tem um valor de LogLik muito alto em módulo. Então foram estimados os modelos GLM para posteriormente compará-los a outros modelos multiníveis. O valor do LogLik de todos foram maiores em módulo que o LogLik do modelo anterior exceto o Não Linear com transformação de “Yeo-Johnson” como mostra a Figura 10, e foi constatado que o modelo ideal seria o Modelo Hierárquico Não Linear com transformação de “Yeo-Johnson”. Outras métricas estatísticas como AIC e BIC foram usadas e foram semelhantes ao LogLik no sentido da escolha do melhor modelo.

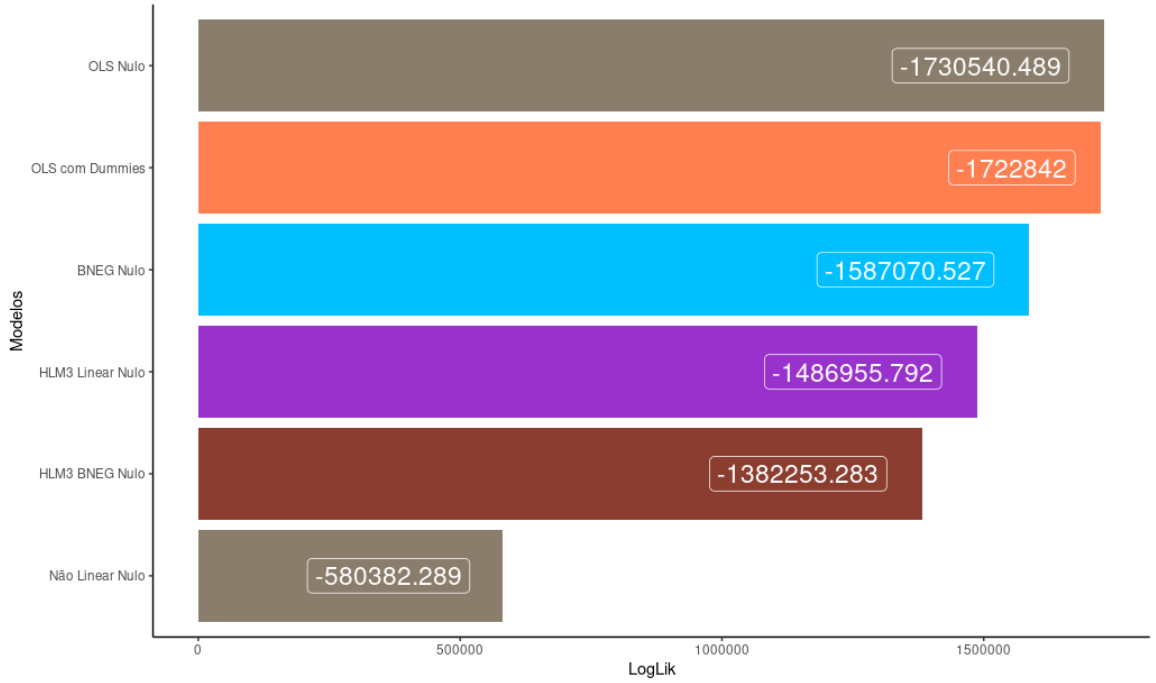

Figura 10. Comparações entre modelos
Fonte: Resultados originais da pesquisa

A Figura 11 mostra que a transformação "Yeo-Johnson" melhorou muito a distribuição dos dados. Normalizou um pouco os dados que tinham formato de uma distribuição binomial negativa, mas não o suficiente para alcançar a homocedasticidade ou a distribuição se tornar aderente à normalidade.

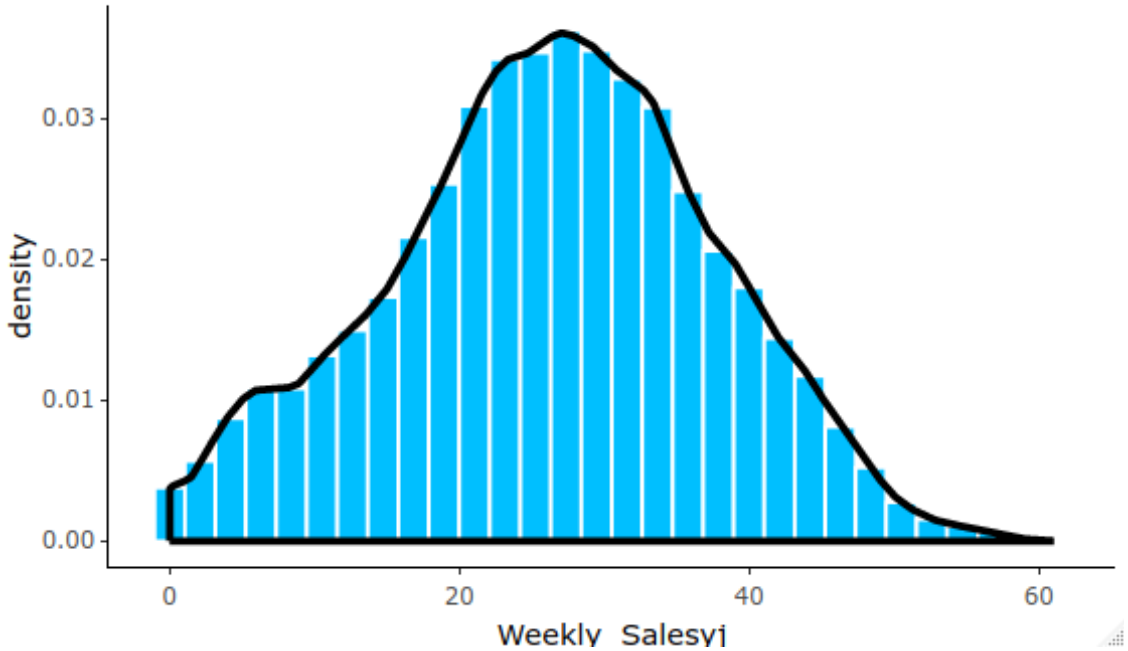

Figura 11. Gráfico de frequência da variável dependente após transformação

Fonte: Resultados originais da pesquisa

Depois de escolher o Modelo Multinível Hierárquico Não Linear HLM3 a próxima etapa é o cálculo dos ICC's. A fórmula do modelo nulo do HLM3 Linear segue abaixo nas equações 3, 4 e 5.

$$Weekly_Sales_{tjk} = \beta_{0jk} + \varepsilon_{tjk} \tag{3}$$

$$\beta_{0jk} = \delta_{000} + \tau_{00k} + v_{0jk} \tag{4}$$

$$Weekly_Sales_{tjk} = \delta_{000} + v_{0jk} + \tau_{00k} + \varepsilon_{tjk} \tag{5}$$

Como foi usado um modelo HLM3 Não Linear a fórmula depois da transformação de "Yeo-Johnson" segue abaixo na equação 6.

$$\frac{Weekly_Sales_{tjk}^{0.2129547} - 1}{0.2129547} = \delta_{000} + v_{0jk} + \tau_{00k} + \varepsilon_{tjk} \tag{6}$$

onde, β0 é o intercepto com efeitos aleatórios; δ00 é o grande intercepto; v0jk e τ00k são valores aleatórios de intercepto; e εtjk: é o erro.

Na fórmula 7 a variável Weekly_Sales foi transformada para Weekly_Salesyj até o final da modelagem onde acontece a transformação inversa para os valores preditos reais. Em seguida o código em R do modelo nulo está na fórmula 8.

$$Weekly_Salesyj_{tjk} = \delta_{000} + v_{0jk} + \tau_{00k} + \varepsilon_{tjk} \tag{7}$$

$$\begin{aligned} modelo_{nuloyj} = lme(\text{fixed} = Weekly_Salesyj \sim 1, \\ random = list(Store = \sim 1, Dept = \sim 1), \\ data = data, method = \text{REML}) \end{aligned} \tag{8}$$

onde lme: é umas das funções do R usada para modelagem multinível, fixed: campo de input da variável dependente em função das variáveis fixas; random: é o campo de input das camadas do modelo multinível; data: campo de input dos dados; method: campo para input do método de estimação

No modelo nulo a variável dependente Weekly_Salesyj é em função do intercepto. (ou seja, 1), “fixed” é a parte fixa do modelo. As outras variáveis do modelo são colocadas neste campo; “Restricted Maximum Likelihood” [REML] refere-se ao método de estimativa de máxima verossimilhança restrita utilizado para estimar os parâmetros do modelo linear misto e torna o processamento menos demandante e “random” é a parte da fórmula dos valores aleatórios, que os níveis são colocados em função da variável da camada 1 "Week".

É importante esclarecer que no caso deste TCC só foi permitido efeitos aleatórios em Week, que foi colocado em função das camadas em "random".

Executando uma função para descobrir os valores aleatórios do modelo nulo os valores de saída foram os mostrados na Tabela 5. São estes valores que devem ser usados para o cálculo dos ICC’s.

Tabela 5. Efeitos aleatórios do modelo nulo HLM3 não linear

	Components	Estimatives	Std_Err	z	p.value
1	Var(t00k)	19.809297	4.64915116	4.260842	0
2	Var(v0jk)	129.688743	3.25323939	39.864494	0
3	Var(e)	5.044328	0.01853225	39.864494	0

Fonte: Resultados originais da pesquisa

Com base na Tabela 5 foram calculados os ICC’s dos níveis tempo, loja e departamento e todos foram estatisticamente significantes. Segundo Coelho(2011) o ICC é a divisão da variância de nível de contexto pelo somatório das variâncias de nível individual e de contexto. Nesta tabela observou-se a confirmação do que foi visto nas figuras anteriores: o valor aleatório de intercepto v0jk indica que há diferenças nos interceptos das vendas entre os departamentos, uma diferença bem expressiva como visto na Figura 8. O valor aleatório de intercepto t00k indica que há diferenças nas vendas entre os interceptos de departamentos de lojas diferentes ao longo do tempo e o valor “e” mostra que o tempo tem pouca influência nas vendas semanais, pois mudam pouco no decorrer do tempo e só é acentuado nos feriados. Nas equações 9, 10 e 11 foram calculados os ICC’s dos níveis departamento, loja e tempo respectivamente.

$$ICC_{departamento} = 129.688743 / (129.688743 + 19.809297 + 5.044328) = 0{,}839179215 \quad (9)$$

$$ICC_{loja} = 19.809297 / (129.688743 + 19.809297 + 5.044328) = 0{,}128180364 \quad (10)$$

$$ICC_{tempo} = 1 - 0{,}128180364 - 0{,}839179215 = 0{,}032640421 \quad (11)$$

Conclusões: 83.92% das vendas semanais é causado pelo nível departamento, 12.82% pelo nível loja e 3.26% pelo nível tempo.

O cálculo dos ICC's é tão eficiente que mostra informações importantes que outro modelo não teria capacidade de mostrar. O mapa de correlações tinha revelado que todas as variáveis de tempo e loja não tinham uma boa correlação com vendas semanais, só a variável Size. Após o cálculo dos ICC's foi descoberto o porquê: Os resultados indicam que a maior parte da variância das vendas semanais ocorre no nível departamento, evidenciando que as diferenças entre departamentos dentro de uma mesma loja são mais relevantes para explicar a variação das vendas do que as diferenças entre lojas. Se mais variáveis de departamento fossem incluídas no dataset o poder de predição do modelo seria cada vez mais eficiente.

Como a influência do tempo foi fraca calculou-se a influência das mesmas camadas sobre as vendas semanais nos feriados para mostrar a eficiência do cálculo dos ICC's. Nas equações 12, 13 e 14 foram calculados os ICC's dos níveis departamento, loja e tempo respectivamente usando estes novos dados mostrados na tabela 6.

Tabela 6. Efeitos aleatórios do modelo nulo HLM3 não linear em Feriados

	Components	Estimatives	Std_Err	z	p.value
1	Var(t00k)	19.36586	4.323561	4.479146	0
2	Var(v0jk)	29.01431	1.335189	21.730488	0
3	Var(e)	83.72326	1.253353	66.799434	0

Fonte: Resultados originais da pesquisa

$$ICC_{departamento} = 29.01431 / (29.01431 + 19.36586 + 83.72326) = 0.219633283 \quad (12)$$

$$ICC_{loja} = 19.36586 / (29.01431 + 19.36586 + 83.72326) = 0.146596194 \quad (13)$$

$$ICC_{tempo} = 1 - 0.146596194 - 0.219633283 = 0.633770523 \quad (14)$$

Nos feriados 21.96% das vendas é devido ao nível departamento, 14.66% do nível loja e 63.38% do nível tempo, comprovando assim a eficácia dos ICC's pois a influência do nível tempo sobre as vendas aumentaria se fosse usado só parte dos dados cuja variável

IsHoliday é igual a 1, ou seja, feriados. Os picos de vendas nos feriados significam que tanto os interceptos quanto a taxa de crescimento das vendas aumentam ao longo do tempo.

Outro Exemplo: Fuel_Price

Foi feito outro exemplo transformando a variável explicativa “Fuel_Price” em variável dependente. Fuel_Price foi escolhida também para provar que o tempo se tornaria muito significativo em alguns casos, mas também por mostrar outra situação.

Ao aplicar a função para achar os valores aleatórios deste outro modelo nulo foi obtido as suas respectivas saídas mostradas na Tabela 7 e nas equações 15, 16 e 17 foram calculados os ICC’s dos níveis departamento, loja e tempo:

Tabela 7. Efeitos aleatórios do modelo nulo HLM3 não linear de Fuel_Price

	Components	Estimatives	Std_Err	z	p.value
1	Var(t00k)	2.783165e-02	6.071580e-03	4.583922	0
2	Var(v0jk)	4.927861e-11	1.038457e-10	0.474537	0.635
3	Var(e)	4.738909e-02	1.722303e-04	275.149608	0

Fonte: Resultados originais da pesquisa

$$ICC_{departamento} = 0 \tag{15}$$

$$ICC_{loja} = 0.02783165 / (0.02783165 + 0.04738909) = 0.369999684 \tag{16}$$

$$ICC_{tempo} = 1 - 0{,}369999684 = 0.630000316 \tag{17}$$

Quando a variável dependente é Fuel_Price a camada que influencia mais nas vendas semanais é o tempo, lembrando que a variável Fuel_Price tem uma alta correlação com Week. O valor do componente aleatório de intercepto do departamento v0jk no modelo nulo é quase zero além de não se mostrar estatisticamente significante, o que significa que não há diferenças no intercepto entre os departamentos no que se refere aos preços de combustível. Isto porque ela não varia entre os departamentos da mesma loja semanalmente, somente entre lojas e no decorrer das semanas. Consequentemente o modelo se transforma em um Modelo Multinível Hierárquico de 2 Níveis [HLM2] Não Linear com Medidas Repetidas cujos níveis são Tempo e Loja.

A figura 12 mostra a comparação de ICC’s dos 3 exemplos.

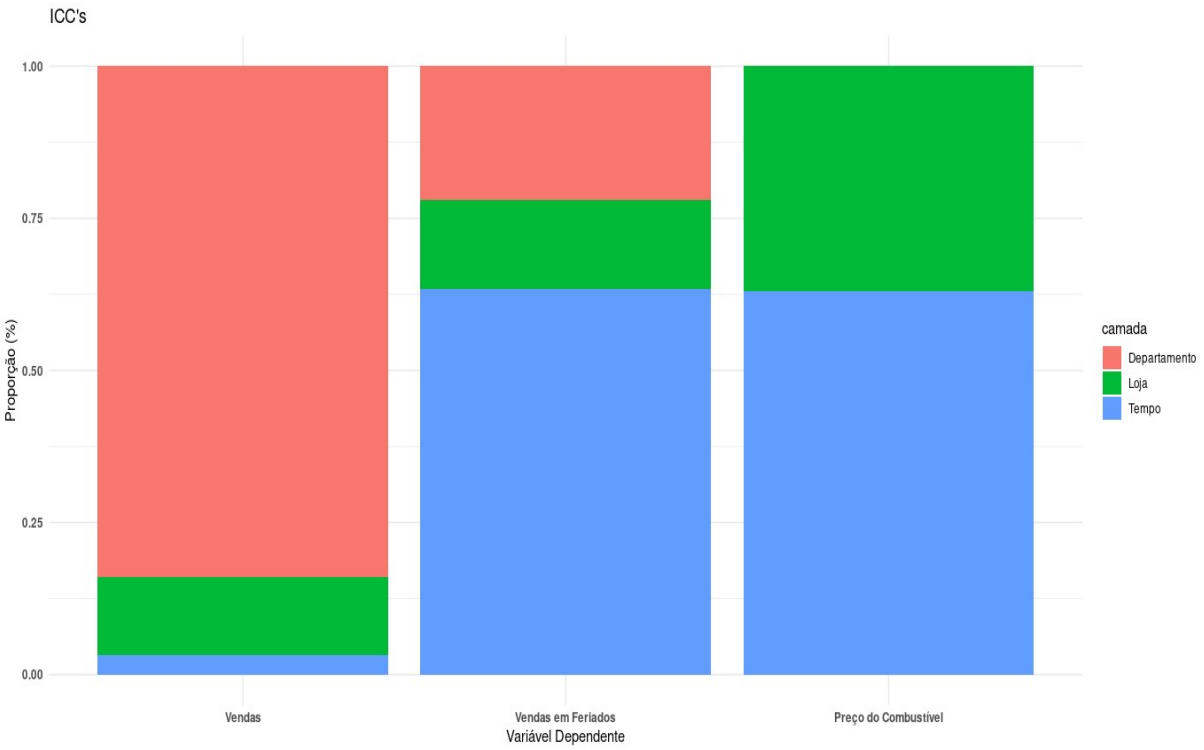

Figura 12. Comparações de ICC's dos modelos nulos da modelagem HLM3
Fonte: Resultados originais da pesquisa

Modelo de Interceptos e inclinações Aleatórias

Após definir qual modelo usar e o cálculo dos ICC's deve-se começar a construção do modelo escolhido, mas seguindo a estratégia Step-Up. Após o modelo nulo a próxima etapa é construir o modelo de interceptos e inclinações.

No modelo de interceptos e inclinações aleatórias são incluídas no modelo nulo as variáveis dos dados de entrada como mostrado nas fórmulas 18, 19, 20, 21 e 22. A fórmula 23 é o comando usado no R.

$$Weekly_Sales_{tjk} = \beta_{0jk} + \beta_{1jk}.Week + \beta_{tjk}.Temperature + \beta_{tjk}.Fuel_Price + \beta_{tjk}.MarkDown1 + \beta_{tjk}.IsHoliday_True + \beta_{tjk}.MarkDown5 + \beta_{tjk}.Unemployment + \beta_{tjk}.CPI + \varepsilon_{tjk} \quad (18)$$

¿
¿

$$\beta_{0jk} = \delta_{000} + \tau_{00k} + v_{0jk} \quad (19)$$

$$\beta_{1jk} = \delta_{100} + \tau_{10k} + v_{1jk} \quad (20)$$

$$Weekly_Salesyj_{tjk} = \frac{Weekly_Sales_{tjk}^{0.2129547} - 1}{0.2129547} \tag{21}$$

$$\begin{aligned} Weekly_Salesyj_{tjk} = {} & \delta_{000} + \delta_{100}.Week + v_{0jk} + v_{1jk}.Week + \tau_{00k} + \\ & \tau_{10k}.Week + \beta_{tjk}.Temperature + \beta_{tjk}.Fuel_Price + \\ & \beta_{tjk}.MarkDown1 + \beta_{tjk}.IsHoliday_True + \beta_{tjk}.MarkDown5 + \\ & \beta_{tjk}.Unemployment + \beta_{tjk}.CPI + \varepsilon_{tjk} \end{aligned} \tag{22}$$

¿
¿

$$\begin{aligned} modelo_intercep_inclinyj = {} & lme(\text{fixed} = Weekly_Salesyj \sim Week + \\ & Temperature + Fuel_Price + MarkDown1 + \\ & IsHoliday_{True} + MarkDown5 + Unemployment + CPI, \\ & random = list(Store = \sim Week, Dept = \sim Week), \\ & data = data, method = \text{REML}) \end{aligned} \tag{23}$$

onde β0 é o intercepto com efeitos aleatórios; β1 é a inclinação com efeitos aleatórios; βtjk é a inclinação dos efeitos fixos das variáveis sem efeitos aleatórios; δ000 é o intercepto; δ100 é a inclinação da variável da camada tempo; v0jk e τ00k são valores aleatórios de intercepto de departamento e loja respectivamente; v1jk e τ10k são valores aleatórios de inclinação de departamento e loja respectivamente e εtjk: é o erro.

No modelo de interceptos e inclinações são inseridos os interceptos e as inclinações das variáveis no modelo, tanto das variáveis aleatórias como fixas.

Na saída do comando *summary(modelo_intercept_inclinyj),* Week e CPI não se mostraram estatisticamente significantes. O tempo estava influenciando muito pouco as vendas semanais, mas mesmo assim todos os efeitos aleatórios foram estatisticamente significantes como mostra a tabela 8.

Tabela 8. Efeitos aleatórios do modelo HLM3 com intercepto e inclinações aleatórias

	Components	Estimatives	Std_Err	z	p.value
1	Var(t00k)	4.033367e+01	9.8147237850	4.109507	0
2	Var(t10k)	5.855669e-04	1.038457e-10	3.919336	0
3	Var(v0jk)	1.274618e+02	3.2465302037	39.260933	0

4	Var(v1jk)	4.361296e-03	0.0001342754	32.480224	0
5	Var(e)	6.346126e+00	0.0235780657	269.153786	0

Fonte: Resultados originais da pesquisa

Na equação 22 e tabela 8 percebe-se que há mais 2 efeitos aleatórios: v1jk (efeito aleatório de inclinação no nível departamento) e t10k(efeito aleatório de inclinação no nível loja) que respectivamente significam: “Têm diferenças nas taxas de vendas entre departamentos ao longo do tempo?” e “Têm diferenças nas taxas de vendas entre departamentos de lojas diferentes ao longo do tempo?”. Como os resultados foram significantes a resposta para as perguntas é sim.

Modelo Completo

No modelo completo as variáveis W são inseridas. Como já foi citado elas são variáveis de nível, pois só variam entre os elementos do nível. Por exemplo: No caso deste TCC as variáveis W são Size (Tamanho de loja) e Type(tipos de loja) da camada de lojas. Cada loja tem seu próprio tipo e tamanho, são invariantes no tempo.

Como não existe variável W no segundo nível “departamento”, somente a fórmula do nível 3 sofre modificações:

$$\gamma_{00k} = \delta_{000} + \delta_{001}.\text{Size} + \delta_{002}.Type_B + \delta_{003}.Type_C + \tau_{00k} \quad (24)$$

$$\gamma_{10k} = \delta_{100} + \delta_{101}.\text{Size} + \delta_{102}.Type_B + \delta_{103}.Type_C + \tau_{10k} \quad (25)$$

Comando usado no R:

$$\begin{aligned} &modelo_finalyj = lme(\text{fixed} = Weekly_Salesyj \sim Week + Temperature + \\ &Fuel_Price + MarkDown1 + IsHoliday_True + MarkDown5 + Unemployment + \\ &CPI + Week:\text{Size} + Week:Type_B + Week:Type_C + \text{Size} + Type_B + Type_C, \\ &random = list(Store = \sim Week, Dept = \sim Week), \\ &data = data, method = \text{REML}) \end{aligned} \quad (26)$$

onde Type_B, Type_C e Size são variáveis W do nível loja.

Ao executar o comando *summary(modelo_finalyj)* no R encontram-se os coeficientes na saída do comando como mostra a Figura 13 e assim a equação final .

```
            StdDev      Corr
(Intercept) 11.25319090 (Intr)
Week         0.05125953 0.062
Residual     2.10440648

Fixed effects:  Weekly_Salesyj ~ Unemployment + CPI + Fuel_Price + MarkDown1 +      Mar
kDown5 + IsHoliday_True + Temperature + Week + Week:Size +      Week:Type_B + Week:Type
_C + Size + Type_B + Type_C
                   Value Std.Error     DF  t-value p-value
(Intercept)    23.741786 0.6705702 148171 35.40537  0.0000
Unemployment    1.296713 0.0843681 148171 15.36970  0.0000
CPI             0.160920 0.3390713 148171  0.47459  0.6351
Fuel_Price      0.041510 0.0084712 148171  4.90012  0.0000
MarkDown1      -0.046658 0.0060371 148171 -7.72856  0.0000
MarkDown5       0.052054 0.0063564 148171  8.18923  0.0000
IsHoliday_True  0.284764 0.0208569 148171 13.65321  0.0000
Temperature     0.043982 0.0104086 148171  4.22558  0.0000
Week           -0.000332 0.0035947 148171 -0.09225  0.9265
Size            4.511479 0.5964620     41  7.56373  0.0000
Type_B          2.449385 1.1039298     41  2.21879  0.0321
Type_C         -0.693303 1.7867961     41 -0.38801  0.7000
Week:Size      -0.007060 0.0030416 148171 -2.32133  0.0203
Week:Type_B    -0.009990 0.0056095 148171 -1.78087  0.0749
Week:Type_C     0.003471 0.0090915 148171  0.38180  0.7026
```

Figura 13. Coeficientes do modelo final e significâncias estatísticas
Fonte: Resultados originais da pesquisa

A variável Week do nível tempo não foi estatisticamente significante quando o modelo completo foi modelado, mas notou-se que a interação com Size foi significante. Size é a variável que está mais correlacionada com Weekly_Sales, pois as vendas semanais aumentam na mesma proporção do tamanho das lojas. Por isso que o tempo ainda é significante na primeira camada.

O modelo final está abaixo. A equação 26 é a equação final adquirida com base na transformação de "Yeo–Johnson" e a equação 27 apresenta a equação final do modelo sem a transformação.

$$Weekly_Salesyj_{tjk} = 23.741786 + 0.043982 . Temperature + 0.041510 . Fuel_Price - 0.046658 . MarkDown1 + 0.284764 . IsHoliday_True + 0.052054 . MarkDown5 + 1.296713 . Unemployment + 4.511479 . \text{Size} + 2.449385 . Type_B - 0.007060 . Week . \text{Size} - 0.009990 . Week . Type_B + v_{1jk} . Week + v_{0jk} + \tau_{00k} + \tau_{10k} . Week + \varepsilon_{tjk} \quad (27)$$

$$Weekly_Sales_{tjk} = \left(\left(Weekly_Salesyj . 0.2129547 \right) + 1 \right)^{1/0.2129547} \quad (28)$$

Para conferir se diferenças abaixo entre o modelo nulo, modelo de intercepto e inclinações aleatórias e o modelo completo são estatisticamente significantes usou-se a função *lrtest()*. Todas as diferenças entre os modelos foram estatisticamente significantes.

Ao confrontar os valores de LogLik do modelo de interceptos aleatórios e o modelo completo com os outros valores realmente o modelo multinível se mostra superior, inclusive até o modelo nulo do HLM3 não linear foi mais superior que os outros. Lembrando que a parte um da comparação na Figura 10 mostra que todos eram inferiores ao modelo não linear nulo.

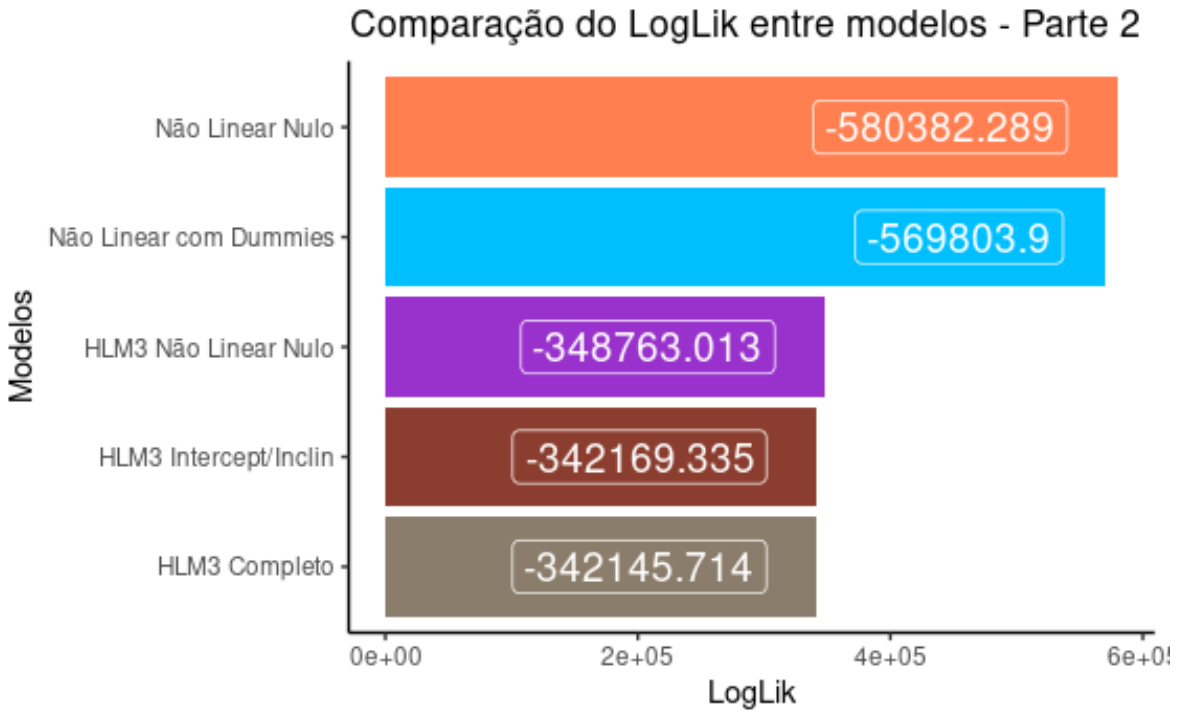

Figura 14. Comparação final entre os modelos
Fonte: Resultados originais da pesquisa

A Figura 15 mostra as outras medidas estatísticas adotadas ao longo do desenvolvimento do modelo: AIC e BIC.

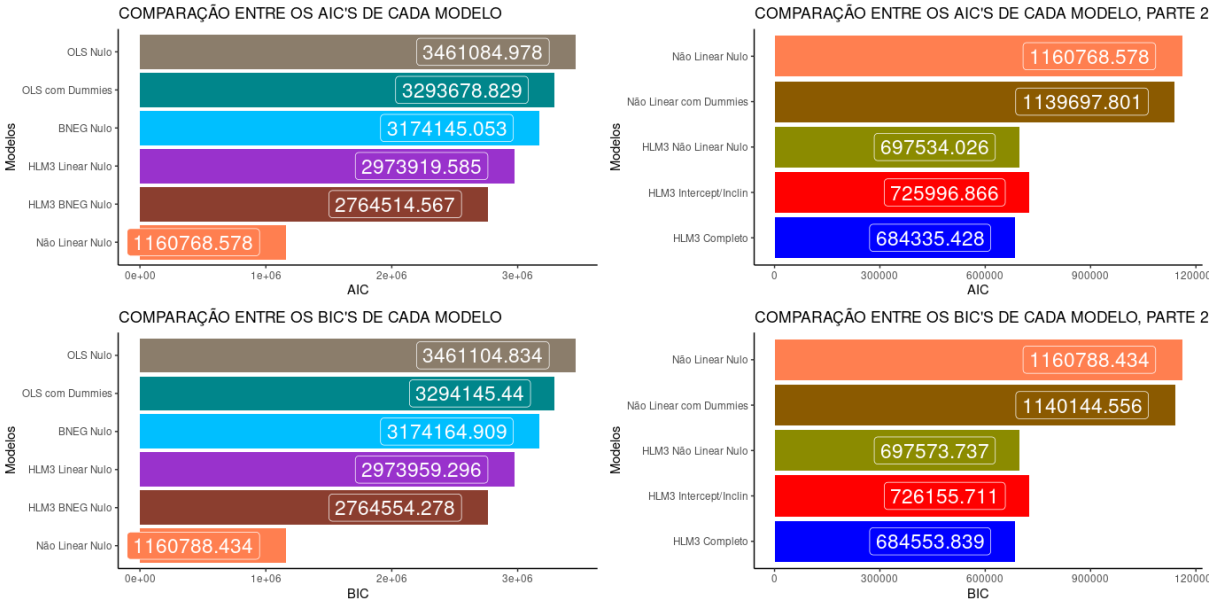

Figura 15. Comparação de AIC e BIC dos modelos
Fonte: Resultados originais da pesquisa

A figura 16 é um panorama de todos dos valores dos efeitos aleatórios v0jk/v1jk do nível departamento e τ0jk/τ1jk do nível loja.

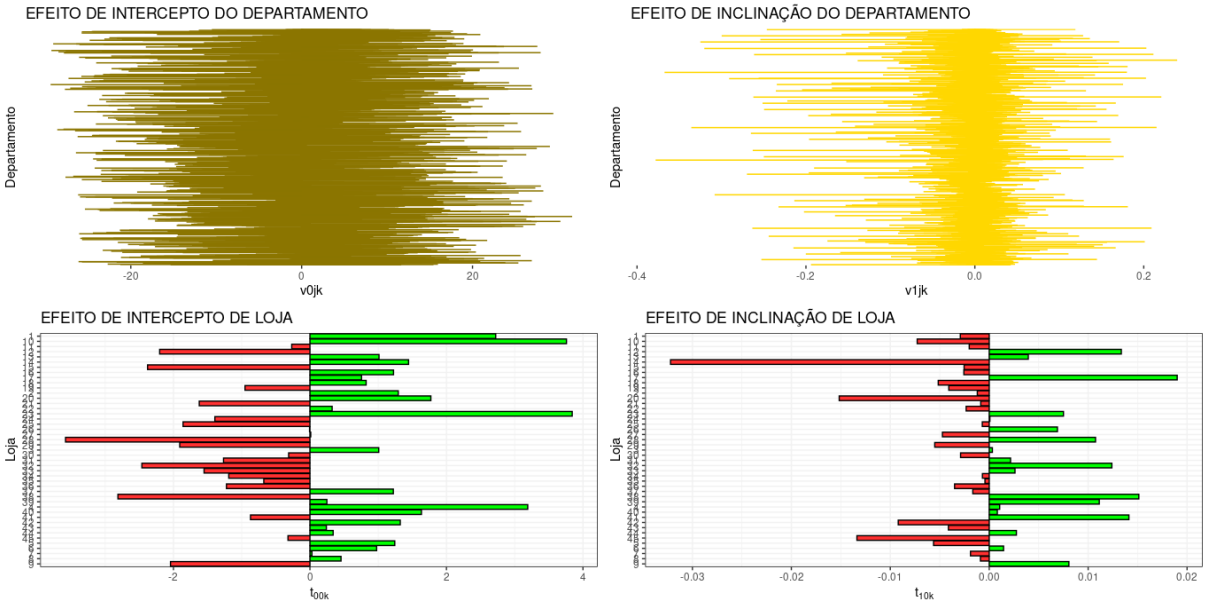

Figura 16. Panorama dos valores aleatórios do modelo
Fonte: Resultados originais da pesquisa

Na Tabela 9, os valores reais estão na coluna “Weekly_Sales” e os valores preditos na coluna “Dept”(nível 2). A coluna “FittedyjOLS” são os valores preditos aplicando regressão linear.

Tabela 9. Alguns valores preditos

Índice	Fixed	Store	Dept	FittedOLS	Weekly_Sales
41	5448.604	8120.840	19061.03	11076.53	17330
42	5459.716	8132.560	19049.42	11002.64	16286
43	5355.014	7985.758	18728.13	11021.83	16680
44	5702.507	8457.120	19611.26	11047.02	18322
45	5408.288	8051.769	18788.77	10956.82	19616
46	5438.132	8089.104	18827.26	10904.09	19251
47	5443.797	8093.370	18801.36	10955.67	18947
48	5175.697	7723.120	18047.29	10700.92	21904
49	5206.259	7761.625	18089.19	10645.00	22764
50	5193.127	7740.283	18014.58	10681.45	24185

Fonte: Resultados originais da pesquisa

As correlações de Weekly_Sales com quase todas as variáveis explicativas são muito fracas como mostrado anteriormente na Figura 5. Os valores preditos poderiam ser mais precisos, mas mesmo assim a modelagem multinível conseguiu prevê-las bem, mesmo permitindo efeitos aleatórios só na variável Week. Se for usado regressão linear, com transformação ou não, a predição fica tão comprometida a ponto do R quadrado ser menor que 0,2 e só aumenta um pouco de valor se a variável dependente for trocada para vendas semanais das lojas, deletando assim a coluna Dept (departamento).

Considerações Finais

O uso da Modelagem Multinível se mostrou muito eficiente quando aplicado aos dados da planilha usada que contém uma estrutura hierárquica. Os valores de ICC mostraram com precisão a contribuição de cada nível para o resultado final do modelo. Este algoritmo captura adequadamente os dados mesmo em um cenário de heterocedasticidade e correlação fraca entre variáveis explicativas e a dependente. Esta eficiência se deve principalmente à capacidade do modelo em calcular os valores aleatórios de cada nível — um aspecto que não é possível ao utilizar outros modelos estatísticos convencionais.

Referências

Fávero,L.P.; Belfiore,P.; Souza.R.F. 2023. Data Science, Analytics and Machine Learning with R, pp 237-258

Fávero, L.P.; Belfiore, P. 2017. Manual de análise de dados. Elsevier, Rio de Janeiro, RJ, Brasil.

Raudenbush, S. W.; Bryk, A. S. 2002. Hierarchical linear models: applications and data analysis methods. 2ed. Sage Publications, Thousand Oaks, CA, USA.,

Riani, Marco; Atkinson, Anthony C.; Corbellini, Aldo. 2023. Automatic robust Box–Cox and extended Yeo–Johnson transformations in regression. SpringerLink Journals

Coelho, F.A.; Borges-Andrade, J.E. 2011. Discussão sobre algumas contribuições da modelagem multinível para a investigação de desempenho no trabalho. Psico-USF, 16(2): 135-142.

Fávero , LP , Santos , MA , & Serra , RG (2018a).Agências transfronteiriças no setor bancário latino-americano.International Journal of Bank Marketing, 36 ,496–528.

Hair, J.F.; Fávero, L.P. 2019. Multilevel modeling for longitudinal data: concepts and applications. RAUSP Management Journal, 54(4): 459-489. Disponível em: <https://www.emerald.com/insight/content/doi/10.1108/
RAUSP-04-2019-0059/full/html>. Acesso em: 28 ago. 2024.